Rayen Chemlali

Toulouse, France +33 6 72 19 39 37 +216 56 042 251 rayen.chemlali@insat.ucar.tn
linkedin.com/in/chemlali-rayen-69aa65243 github.com/Rayen-Chemlali rayen-chemlali.vercel.app

RÉSUMÉ

Actuellement étudiant à l'INP Toulouse – ENSEEIHT (N7), dans le cadre d'un échange académique, je poursuis ma dernière année du cycle ingénieur, spécialité HPC Big Data, en parallèle d'un Master parcours PSMSC (Scientific Computing). Je suis issu d'une formation de 4 ans en Génie Logiciel à l'INSAT (Institut National des Sciences Appliquées et de Technologie), en Tunisie. Passionné par les mathématiques et l'informatique, j'ai pris part au fil de mon cursus à plusieurs compétitions de programmation et hackathons, tout en accumulant des expériences professionnelles en stages, freelance et temps partiel.

COMPÉTENCES CLÉS

— **IA Générative & Agentique :** NLP, LLMs (prompt engineering, fine-tuning, embeddings), RAG, IA Agentique, architecture multi-agents, tool calling, LangChain, LangGraph, Qdrant

— **Machine Learning & Deep Learning :** Apprentissage Supervisé & Non Supervisé, CNN, Transformer Architecture, séries temporelles, classification audio

— **Calcul Scientifique & HPC :** calcul parallèle et distribué, algorithmes HPC, OpenMP, MPI, CUDA, OpenCL

— **Optimisation :** Recherche opérationnelle (PL, PLNE), algorithmes de recherche avec heuristiques (A*), Gurobi

— **Big Data :** Hadoop, Spark, Kafka

— **Langages de programmation :** Python, C++, Java, Go, JavaScript, PHP

— **Frameworks :** FastAPI, NestJS, ASP.NET, Symfony, React, Next.js, Angular

— **Développement logiciel & Outils :** Architecture logicielle, Design Patterns, Bases de données relationnelles et non-relationnelles, Neo4j, Git, Docker, Kubernetes, CI/CD, DevOps

EXPÉRIENCE PROFESSIONNELLE

Plug & Tel

Stagiaire ML *Juin 2026 – Août 2026*

Amélioration du taux d'erreur de classification d'un modèle IA de détection de répondeur (AMD) en production, tout en maintenant une latence compatible avec les contraintes temps réel des flux VoIP. Exploration de plusieurs approches : modèles tabulaires, CNN sur mel-spectrogrammes, et modèles hybrides combinant les deux. Mise en œuvre de l'explicabilité des modèles : Grad-CAM pour les CNN et explicabilité des modèles tabulaires.

Ingénieur Logiciel à temps partiel *Novembre 2025 – Avril 2026*

Travail en tant qu'ingénieur logiciel à temps partiel, contribuant à des projets de développement logiciel et appliquant des compétences techniques dans un cadre professionnel, notamment le développement de microservices VoIP en Go et la participation au processus de déploiement en production.

Elevvo Pathways

Stagiaire ML *Mars 2026*

Réalisation de 5 projets ML complets couvrant le clustering, la classification, la prévision de séries temporelles, la vision par ordinateur et la classification audio. Maîtrise du pipeline ML complet du prétraitement des données jusqu'à l'évaluation des modèles.

Code

Talan Tunisie Consulting

Stagiaire d'été *Juin 2025 – Août 2025*

Conception et développement de la première phase du Smart Container Registry pour optimiser les coûts de stockage Docker, incluant un chatbot conversationnel avec tool calling dynamique, un tableau de bord unifié Kubernetes/S3 et des règles de suppression personnalisées.

Frontend *Backend* *Demo*

Freelance

Développeur Logiciel *Dates diverses*

Travaillé sur deux projets freelance :

— **Strategy Copilot** : Copilote stratégique d'affaires alimenté par l'IA avec chatbot et visualisations graphiques, générant des diagnostics, des projections financières et des analyses de marché avec exports PDF.

— **Shannon** : Co-développement d'un générateur de code C++ pour cartes électroniques de la société Shannon, basé sur une modélisation par graphes, avec application de bureau PyQt5 et canvas interactif inspiré de Simulink. *Démo*

PROJETS

— **Multi-Agent Travel Planning System** Jan 2026 – Juin 2026
Système de planification de voyages personnalisé piloté par plusieurs agents IA avec interaction conversationnelle, RAG et construction progressive de la base de connaissance. Mémoire persistante multi-niveaux et temps de réponse optimisé via pré-calcul en arrière-plan ; évalué par des tests automatisés simulant des utilisateurs de différents personas.
LLMs, LangChain, LangGraph, RAG, Qdrant *Démo* *Rapport (détails complets de l'architecture)*

— **Smart City Platform** Jan 2026 – Juin 2026
Plateforme d'intelligence urbaine implémentant un pipeline Big Data complet combinant traitement batch hebdomadaire et streaming temps réel sur 6 datasets réels (trafic, énergie, criminalité). Calcul via MLlib des poids du City Pulse Score, un indicateur composite par quartier pour le monitoring urbain continu.
Hadoop, Spark, Kafka, MLlib

— **SoundGuard (Samsung Innovation Campus)** Oct 2025 – Nov 2025
Projet de fin de programme en IA : détection en temps réel de bruits dangereux pour protéger l'audition des travailleurs ; le système classifie les signaux audio et déclenche des alertes quand l'exposition dépasse les seuils de sécurité.
Démo *Code*

— **MediSys** Mar 2025 – Juin 2025
Plateforme de gestion médicale couvrant les consultations, rendez-vous, prescriptions et analyses. Numérisation automatique de documents médicaux par OCR. Inclut un chatbot conversationnel qui recommande des médecins et médicaments proches et adaptés au cas du patient.
NestJS, Next.js, GraphQL, Python, LLMs, OCR *Frontend* *Backend* *Démo*

— **Calcul GPU Hétérogène (CUDA/OpenCL)** Avr – Mai 2025
Deux projets réalisés dans le cadre de la même matière : répartition dynamique de la charge entre CPU, iGPU et dGPU en OpenCL, atteignant un gain de vitesse de 1.23× par rapport au GPU seul ; et optimisation de kernels CUDA (tiling, vectorisation float4, TensorCores), atteignant 1235 GFLOPS, à moins de 6% des performances de cuBLAS.
CUDA, OpenCL, cuBLAS, C++ *Rapports*

— **Optimisation en Recherche Opérationnelle** Avr – Mai 2025
Modélisation et résolution de trois problèmes NP-difficiles avec Gurobi (transport, VRP avec élimination de sous-tours MTZ, localisation d'installations), incluant analyse duale et de sensibilité. Livraison de deux applications complètes : une plateforme web Next.js/FastAPI avec visualisation interactive des itinéraires, et une application de bureau PyQt5.
Python, Gurobi, Next.js, FastAPI *Code* *Rapport*

FORMATION

INP Toulouse – ENSEEIHT *2026 – 2027*
– 5ème année, parcours HPC Big Data (échange académique)
– Master parcours PSMSC (Scientific Computing)

Institut National des Sciences Appliquées et de Technologie *2022 – 2026*
1ère à 4ème année en Génie Logiciel

Baccalauréat en Mathématiques, Tunisie *2022*
Mention Très Bien

LANGUES

Arabe – Langue maternelle **Français** – Courant **Anglais** – Courant **Espagnol** – Débutant

CERTIFICATIONS

— Samsung Innovation Campus AI Program
— Efficient LLM Customization (NVIDIA)
— Building RAG Agents with LLMs (NVIDIA)

RÉALISATIONS

— Gagnant thématique Enedis – Hackathon AI For Impact by La Mêlée, Oct 2026
— Top 6 – Data Quest 2026, Fév 2026 *Code* *Demo*
— 3ème place – Hackathon AI 4 New Generation, EY & Univ. Ibn Khaldoun, 2024
— Médaille de bronze (11ème) – TCPC 2024
— 2ème place – Code Quest 2023, INSAT