Rayen Chemlali

Toulouse, France +33 6 72 19 39 37 +216 56 042 251 rayen.chemlali@etu.toulouse-inp.fr
linkedin.com/in/chemlali-rayen-69aa65243 github.com/Rayen-Chemlali rayen-chemlali.vercel.app

RÉSUMÉ

Actuellement étudiant à l'INP Toulouse – ENSEEIHT (N7), dans le cadre d'un échange académique, je poursuis ma dernière année du cycle ingénieur, spécialité HPC Big Data, en parallèle d'un Master parcours PSMSC (Scientific Computing). Je suis issu d'une formation de 4 ans en Génie Logiciel à l'INSAT (Institut National des Sciences Appliquées et de Technologie), en Tunisie. Passionné par les mathématiques et l'informatique, j'ai pris part au fil de mon cursus à plusieurs compétitions de programmation et hackathons, tout en accumulant des expériences professionnelles en stages, freelance et temps partiel.

COMPÉTENCES CLÉS

— **IA Générative & Agentique :** NLP, LLMs (prompt engineering, fine-tuning, embeddings), RAG, IA Agentique, architecture multi-agents, tool calling, LangChain, LangGraph, Qdrant

— **Machine Learning & Deep Learning :** Apprentissage Supervisé & Non Supervisé, CNN, Transformer Architecture, séries temporelles, classification audio

— **Calcul Scientifique & HPC :** calcul parallèle et distribué, algorithmes HPC, OpenMP, MPI, CUDA, OpenCL

— **Optimisation :** Recherche opérationnelle (PL, PLNE), algorithmes de recherche avec heuristiques (A*), Gurobi

— **Big Data :** Hadoop, Spark, Kafka

— **Langages de programmation :** Python, C++, Java, Go, JavaScript, PHP

— **Frameworks :** FastAPI, NestJS, ASP.NET, Symfony, React, Next.js, Angular

— **Développement logiciel & Outils :** Architecture logicielle, Design Patterns, Bases de données relationnelles et non-relationnelles, Git, Docker, Kubernetes, CI/CD, DevOps

EXPÉRIENCE PROFESSIONNELLE

Plug & Tel

Stagiaire ML *Juin 2026 – Août 2026*

- Amélioration du taux d'erreur de classification d'un modèle IA de détection de répondeur (AMD) en production.
- Maintien d'une latence compatible avec les contraintes temps réel des flux VoIP.
- Exploration de plusieurs approches : modèles tabulaires, CNN sur mel-spectrogrammes et modèles hybrides combinant les deux.
- Explicabilité des modèles : Grad-CAM pour les CNN et explicabilité des modèles tabulaires.

Ingénieur Logiciel à temps partiel *Novembre 2025 – Avril 2026*

- Développement de microservices VoIP en Go.
- Participation au processus de déploiement en production.

Elevvo Pathways

Stagiaire ML *Mars 2026*

- Réalisation de 5 projets ML complets : clustering, classification, prévision de séries temporelles, vision par ordinateur et classification audio.
- Maîtrise du pipeline ML complet, du prétraitement des données jusqu'à l'évaluation des modèles. *Code*

Talan Tunisie Consulting

Stagiaire d'été *Juin 2025 – Août 2025*

- Conception et développement complet du Smart Container Registry, une alternative à AWS ECR adossée à S3, pour optimiser les coûts de stockage des images Docker en environnement Kubernetes.
- Agent IA à tool calling dynamique pour l'analyse des coûts de stockage.
- Tableau de bord unifié Kubernetes/S3 et moteur de règles de suppression automatique des images. *Frontend* *Backend* *Demo*

Freelance

Développeur Logiciel *Dates diverses*

- **Strategy Copilot** : Copilote stratégique d'affaires alimenté par l'IA avec chatbot et visualisations graphiques, générant des diagnostics, des projections financières et des analyses de marché avec exports PDF.
- **Shannon** : Co-développement d'un générateur de code C++ pour cartes électroniques de la société Shannon, basé sur une modélisation par graphes, avec application de bureau PyQt5 et canvas interactif inspiré de Simulink. *Démo*

PROJETS

— **Multi-Agent Travel Planning System** *LLMs, LangChain, LangGraph, RAG, Qdrant* Jan 2026 – Juin 2026
- Planification de voyages personnalisée pilotée par plusieurs agents IA, avec interaction conversationnelle et RAG.
- Base de connaissance construite progressivement, mémoire persistante multi-niveaux et pré-calcul en arrière-plan.
- Évaluation par des tests automatisés simulant des utilisateurs de différents personas. *Démo* *Rapport*

— **EnedisPO – Copilote de dispatch en crise** *Python, FastAPI, RO, recherche locale, Mistral, React* Oct 2026
- Gagnant Enedis (Hackathon AI For Impact) : architecture complète d'un système d'aide au dispatch en crise.
- Moteur d'optimisation (règle de Smith + recherche locale) minimisant clients × heures sans courant, re-planifié en moins de 3 s.
- Copilote LLM qui explique le plan et traduit les refus en contraintes chiffrées. *Code*

— **MediSys** *NestJS, Next.js, GraphQL, Python, LLMs, OCR* Mar 2025 – Juin 2025
- Plateforme de gestion médicale : consultations, rendez-vous, prescriptions et analyses.
- Numérisation automatique de documents médicaux par OCR.
- Agent IA conversationnel qui recommande des médecins et médicaments proches et adaptés au cas du patient. *Frontend* *Backend* *Démo*

— **Classification de Sons Respiratoires (ICBHI 2017)** *Python, Transformers audio, CNN, BiLSTM* Fév – Avr 2026
- Projet de recherche en Deep Learning sur la détection de sons respiratoires anormaux.
- Reproduction d'un article récent, puis plusieurs approches testées pour l'améliorer : CNN-BiLSTM avec attention, DeiT sur Mel et cochléagramme, AST avec SAM, Focal Loss, logit adjustment.
- Sensibilité de 73% contre 68% pour l'article. *Code* *Rapport*

— **SoundGuard (Samsung Innovation Campus)** Oct 2025 – Nov 2025
- Projet de fin de programme en IA : détection en temps réel de bruits dangereux pour protéger l'audition des travailleurs.
- Classification des signaux audio et alertes quand l'exposition dépasse les seuils de sécurité. *Démo* *Code*

— **Smart City Platform** *Hadoop, Spark, Kafka, MLlib* Jan 2026 – Juin 2026
- Plateforme d'intelligence urbaine avec un pipeline Big Data complet : traitement batch hebdomadaire et streaming temps réel sur 6 datasets réels (trafic, énergie, criminalité).
- Poids du City Pulse Score (indicateur composite par quartier) calculés via MLlib.

— **Calcul GPU Hétérogène (CUDA/OpenCL)** *CUDA, OpenCL, cuBLAS, C++* Avr – Mai 2025
- Deux projets réalisés dans le cadre de la même matière.
- Répartition dynamique de la charge entre CPU, iGPU et dGPU en OpenCL : gain de vitesse de 1.23× par rapport au GPU seul.
- Optimisation de kernels CUDA (tiling, vectorisation float4, TensorCores) : 1235 GFLOPS, à moins de 6% des performances de cuBLAS. *Rapports*

— **Optimisation en Recherche Opérationnelle** *Python, Gurobi, Next.js, FastAPI* Avr – Mai 2025
- Modélisation et résolution de trois problèmes NP-difficiles avec Gurobi (transport, VRP avec élimination de sous-tours MTZ, localisation d'installations), avec analyse duale et de sensibilité.
- Deux applications complètes : une plateforme web Next.js/FastAPI avec visualisation interactive des itinéraires, et une application de bureau PyQt5. *Code* *Rapport*

FORMATION

INP Toulouse – ENSEEIHT *2026 – 2027*
– 5ème année, parcours HPC Big Data (échange académique)
– Master parcours PSMSC (Scientific Computing)

Institut National des Sciences Appliquées et de Technologie *2022 – 2026*
1ère à 4ème année en Génie Logiciel

Baccalauréat en Mathématiques, Tunisie *2022*
Mention Très Bien

LANGUES

Arabe – Langue maternelle **Français** – Courant **Anglais** – Courant **Espagnol** – Débutant

CERTIFICATIONS

— Samsung Innovation Campus AI Program
— Efficient LLM Customization (NVIDIA)
— Building RAG Agents with LLMs (NVIDIA)

RÉALISATIONS

— Gagnant thématique Enedis – Hackathon AI For Impact by La Mêlée, Oct 2026
— Top 6 – Data Quest 2026, Fév 2026 *Code* *Demo*
— 3ème place – Hackathon AI 4 New Generation, EY & Univ. Ibn Khaldoun, 2024
— Médaille de bronze (11ème) – TCPC 2024
— 2ème place – Code Quest 2023, INSAT